Probability of Default

2020 年 4 月 20 日

0.1 Homework7: 判断违约概率

- 2020 年 4 月 20 日
- 周嘉楠 19210980081

0.1.1 问题 1. 读入数据并了解各个自变量的含义

1.1 导入数据

[18]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn import preprocessing
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import MinMaxScaler
from sklearn.preprocessing import LabelEncoder
from sklearn.linear_model import LogisticRegression as LR
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
from sklearn import linear_model
from sklearn.metrics import roc_curve, auc
%matplotlib inline
plt.rcParams['font.sans-serif']=['SimHei']
```

[19]:
```
lines = np.loadtxt('simudata.csv', delimiter=',', dtype='str')
print('数据集大小:',lines.shape[0]-1)
print('数据集特征:',lines.shape[1])
print('数据集特征列表:',lines[0])
```

数据集大小: 8032
数据集特征: 27

```
数据集特征列表: ['creded' 'debitF' 'meanpay' 'billnum' 'debitM' 'zhongxingM'␣
↪'sidaM'
 'xindaiR' 'cardnum' 'xindaiF' 'maxpay' 'zhuanzhangF' 'gongjiaoF'
 'zhuanzhangR' 'age' 'gongjiaoR' 'sidaF' 'sidaR' 'zhongxingF' 'zhongxingR'
 'xiaofeiF' 'jinkaF' 'zhuanzhangM' 'gongjiaoM' 'youxiM' 'xindaiS' 'black']
```

[20]:
```
data = pd.DataFrame(lines[1:],columns=lines[0],dtype='float64')
data.head()
```

[20]:

	creded	debitF	meanpay	billnum	debitM	zhongxingM	sidaM	\
0	0.02	28.0	474795.0	4.0	784137.54	56826.0	307042.0	
1	0.16	2.0	346573.0	32.0	1217.43	43644.0	15096.0	
2	0.32	56.0	168844.0	191.0	95001.76	279217.0	69815.0	
3	0.01	28.0	69002.0	89.0	487782.48	273731.0	329437.0	
4	0.19	6.0	408647.0	104.0	22039.56	13529.0	24725.0	

	xindaiR	cardnum	xindaiF	…	sidaR	zhongxingF	zhongxingR	xiaofeiF	\
0	365.00	2.0	6.0	…	7.83	4.0	334.38	6.0	
1	311.73	9.0	0.0	…	91.77	14.0	365.00	1.0	
2	42.32	8.0	0.0	…	36.05	10.0	27.08	1.0	
3	81.60	15.0	1.0	…	10.08	8.0	191.04	1.0	
4	254.60	17.0	9.0	…	324.21	23.0	248.39	7.0	

	jinkaF	zhuanzhangM	gongjiaoM	youxiM	xindaiS	black
0	9.0	508646.02	297.83	66.02	5760.22	1.0
1	11.0	425876.24	3521.03	22.75	83872.62	1.0
2	2.0	492287.84	467.64	6.66	31110.55	1.0
3	8.0	240067.26	288.67	119.98	7876.13	1.0
4	0.0	455464.47	11834.25	28.97	13765.38	0.0

[5 rows x 27 columns]

[21]:
```
# 定量变量
quant_var = list(data.loc[:,data.columns != 'black'].columns)
print('定量特征有: ',len(quant_var),'个')
print('定量特征为: ',quant_var)
```

```
print('定量特征描述：\n',data.loc[:,data.columns != 'black'].astype('float').
↪describe())
```

定量特征有： 26 个

定量特征为： ['creded', 'debitF', 'meanpay', 'billnum', 'debitM', 'zhongxingM', 'sidaM', 'xindaiR', 'cardnum', 'xindaiF', 'maxpay', 'zhuanzhangF', 'gongjiaoF', 'zhuanzhangR', 'age', 'gongjiaoR', 'sidaF', 'sidaR', 'zhongxingF', 'zhongxingR', 'xiaofeiF', 'jinkaF', 'zhuanzhangM', 'gongjiaoM', 'youxiM', 'xindaiS']

定量特征描述：

	creded	debitF	meanpay	billnum	debitM	\
count	8032.000000	8032.000000	8.032000e+03	8032.000000	8.032000e+03	
mean	0.144796	35.455802	2.717996e+05	74.471489	3.050731e+05	
std	0.143946	35.141984	2.352257e+05	71.310466	2.597760e+05	
min	0.000000	0.000000	0.000000e+00	0.000000	2.600000e+01	
25%	0.020000	5.000000	5.047525e+04	11.000000	5.930946e+04	
50%	0.100000	25.000000	2.312770e+05	55.000000	2.648380e+05	
75%	0.240000	57.000000	4.253420e+05	119.000000	4.796458e+05	
max	0.820000	202.000000	1.346594e+06	427.000000	1.436086e+06	

	zhongxingM	sidaM	xindaiR	cardnum	xindaiF	…	\
count	8.032000e+03	8.032000e+03	8032.000000	8032.000000	8032.000000	…	
mean	1.617706e+05	2.715348e+05	163.339720	6.394796	4.159985	…	
std	1.714516e+05	2.460283e+05	104.671216	4.379306	3.633870	…	
min	3.000000e+00	1.000000e+01	0.020000	0.000000	0.000000	…	
25%	2.161650e+04	4.469200e+04	70.175000	3.000000	1.000000	…	
50%	9.791300e+04	2.197690e+05	155.520000	6.000000	4.000000	…	
75%	2.610935e+05	4.338408e+05	241.020000	9.000000	7.000000	…	
max	1.017770e+06	1.299826e+06	365.000000	26.000000	20.000000	…	

	sidaF	sidaR	zhongxingF	zhongxingR	xiaofeiF	\
count	8032.000000	8032.000000	8032.000000	8032.000000	8032.000000	
mean	25.263446	148.532261	7.812251	237.543242	2.578312	
std	25.356962	99.256973	8.336176	106.227388	3.035972	
min	0.000000	0.160000	0.000000	0.170000	0.000000	
25%	4.000000	57.222500	1.000000	157.150000	0.000000	
50%	17.000000	136.135000	5.000000	251.330000	1.000000	
75%	42.000000	219.947500	13.000000	340.050000	4.000000	

```
max     144.000000   365.000000    53.000000   365.000000    19.000000
```

```
            jinkaF   zhuanzhangM     gongjiaoM       youxiM        xindaiS
count  8032.000000  8.032000e+03   8032.000000  8032.000000    8032.000000
mean      6.101469  3.046979e+05   6079.254307   209.638073  106103.725818
std       7.047664  2.963735e+05   7530.265840   260.277361   94056.103030
min       0.000000  3.821000e+01      0.020000     0.000000       8.050000
25%       1.000000  4.583786e+04    804.827500    28.047500   18240.015000
50%       3.000000  2.145178e+05   2245.550000    75.050000   87971.440000
75%      10.000000  4.963003e+05   9483.372500   329.990000  165942.247500
max      44.000000  1.650050e+06  55745.070000  1939.000000  485178.350000
```

```
[8 rows x 26 columns]
```

1.2 缺失值处理 结论：数据完整，没有缺失值

[22]:
```
# 查看每列数据是否有缺失值：没有缺失值
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8032 entries, 0 to 8031
Data columns (total 27 columns):
creded          8032 non-null float64
debitF          8032 non-null float64
meanpay         8032 non-null float64
billnum         8032 non-null float64
debitM          8032 non-null float64
zhongxingM      8032 non-null float64
sidaM           8032 non-null float64
xindaiR         8032 non-null float64
cardnum         8032 non-null float64
xindaiF         8032 non-null float64
maxpay          8032 non-null float64
zhuanzhangF     8032 non-null float64
gongjiaoF       8032 non-null float64
zhuanzhangR     8032 non-null float64
age             8032 non-null float64
gongjiaoR       8032 non-null float64
```

```
sidaF           8032 non-null float64
sidaR           8032 non-null float64
zhongxingF      8032 non-null float64
zhongxingR      8032 non-null float64
xiaofeiF        8032 non-null float64
jinkaF          8032 non-null float64
zhuanzhangM     8032 non-null float64
gongjiaoM       8032 non-null float64
youxiM          8032 non-null float64
xindaiS         8032 non-null float64
black           8032 non-null float64
dtypes: float64(27)
memory usage: 1.7 MB
```

0.1.2 问题 2：对变量交易笔数和所有用户行为均值分别绘制违约组和非违约组的对比箱线图，并分析是否违约与这些变量之间的关系，给出解读

0.1.3 2.1 交易笔数

[56]:
```
# 进行索引
billnum_def = np.array(data['billnum'])[np.where(data['black']==1)]
billnum_udf = np.array(data['billnum'])[np.where(data['black']==0)]

# 画出箱线图
plt.figure(figsize=(13, 4))
plt.subplot(121)
labels = ['违约组','未违约组']
plt.boxplot([billnum_def,billnum_udf],labels=labels)
plt.title("箱线图:交易笔数 vs 违约情况",fontsize='large')
plt.xlabel('图 2-1 交易笔数 vs 违约情况',fontsize='medium')
plt.ylabel('交易笔数',fontsize='medium')
plt.show()
```

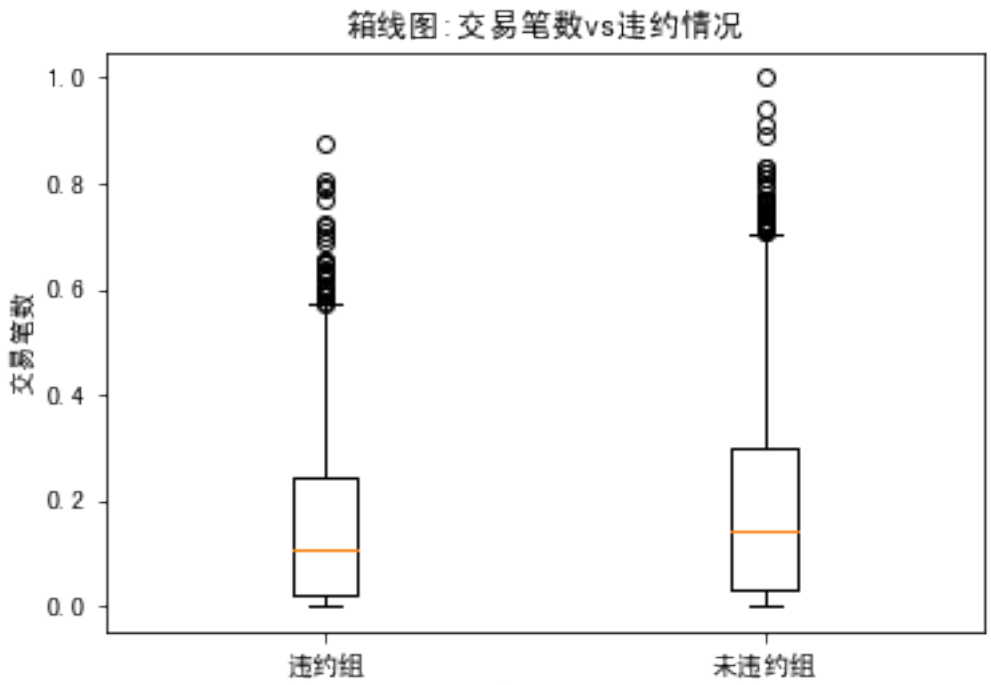

图2-1 交易笔数vs违约情况

从交易笔数 vs 违约情况的箱线图中可以看到，未违约组的交易笔数中位数明显高于违约组的交易笔数，同时未违约组有较多交易笔数更大的用户（离群值更高）。

0.1.4 2.2 所有行为均值

[57]:
```
# 进行索引
meanpay_def = np.array(data['meanpay'])[np.where(data['black']==1)]
meanpay_udf = np.array(data['meanpay'])[np.where(data['black']==0)]

# 画出箱线图
plt.figure(figsize=(13, 4))
plt.subplot(121)
labels = ['违约组','未违约组']
plt.boxplot([meanpay_def,meanpay_udf],labels=labels)
plt.title("箱线图:所有行为均值 vs 违约情况",fontsize='large')
plt.xlabel('图 2-1 所有行为均值 vs 违约情况',fontsize='medium')
plt.ylabel('所有行为均值',fontsize='medium')
plt.show()
```

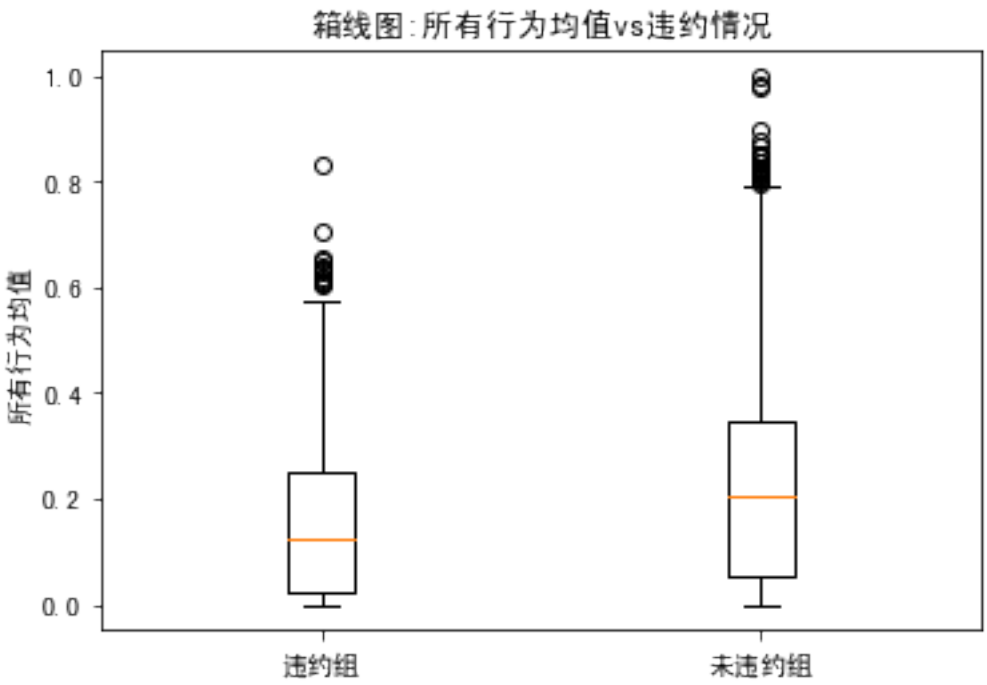

图2-1 所有行为均值vs违约情况

从所有行为均值 vs 违约情况的箱线图中可以看到，未违约组的所有行为均值中位数明显高于违约组的所有行为均值，意味着未违约组用户所有交易行为的平均金额更高，与正常情况相符，而违约组的所有交易行为的平均金额较低，意味着用户财务状况和消费能力较差。

0.1.5 问题 3. 用全部样本数据，以是否违约为因变量建立逻辑回归模型，利用 BIC 准则进行变量筛选，观察最终得到的回归系数并尝试解释对系数进行解释

3.1 数据处理：将定量变量归一化

[25]:
```
# 对定量变量做归一化处理（输出结果是 0~1 之间数值）
data[quant_var] = MinMaxScaler().fit_transform(data[quant_var])
```

3.2 提取数据

[26]:
```
# 提取表格中的特征 features、标签 labels
x_total = np.array(data.loc[:, data.columns != 'black'].astype('float'))
y_total = np.array(data.loc[:, data.columns == 'black'].astype('float')).
 ↪flatten()    # 将 y_total 变为行向量


# 标签分类定位
```

```
# 定位出所有 y_total 为 1 的索引值 (pos_index 属性为 tuple)
pos_index = np.where(y_total == 1)
# 定位出所有 y_total 为 0 的索引值 (neg_index 属性为 tuple)
neg_index = np.where(y_total == 0)
```

3.3 逻辑回归模型:L1 正则化

[59]:
```
# 分别做 L1、L2 正则化，并画图选择最优参数

l1 = []
l2 = []
l1test = []
l2test = []

Xtrain, Xtest, Ytrain, Ytest = train_test_split(x_total,y_total,test_size=0.
↪3,random_state=420)

for i in np.linspace(0.05,1,19):

    lrl1 = LR(penalty="l1",solver="liblinear",C=i,max_iter=1000)
    lrl2 = LR(penalty="l2",solver="liblinear",C=i,max_iter=1000)

    lrl1 = lrl1.fit(Xtrain,Ytrain)
    l1.append(accuracy_score(lrl1.predict(Xtrain),Ytrain))
    l1test.append(accuracy_score(lrl1.predict(Xtest),Ytest))

    lrl2 = lrl2.fit(Xtrain,Ytrain)
    l2.append(accuracy_score(lrl2.predict(Xtrain),Ytrain))
    l2test.append(accuracy_score(lrl2.predict(Xtest),Ytest))

graph = [l1,l2,l1test,l2test]
color = ["green","black","lightgreen","gray"]
label = ["L1","L2","L1test","L2test"]

plt.figure(figsize=(6, 6))
for i in range(len(graph)):
    plt.plot(np.linspace(0.05,1,19),graph[i],color[i],label=label[i])
```

```
plt.legend(loc=4)
plt.show()
```

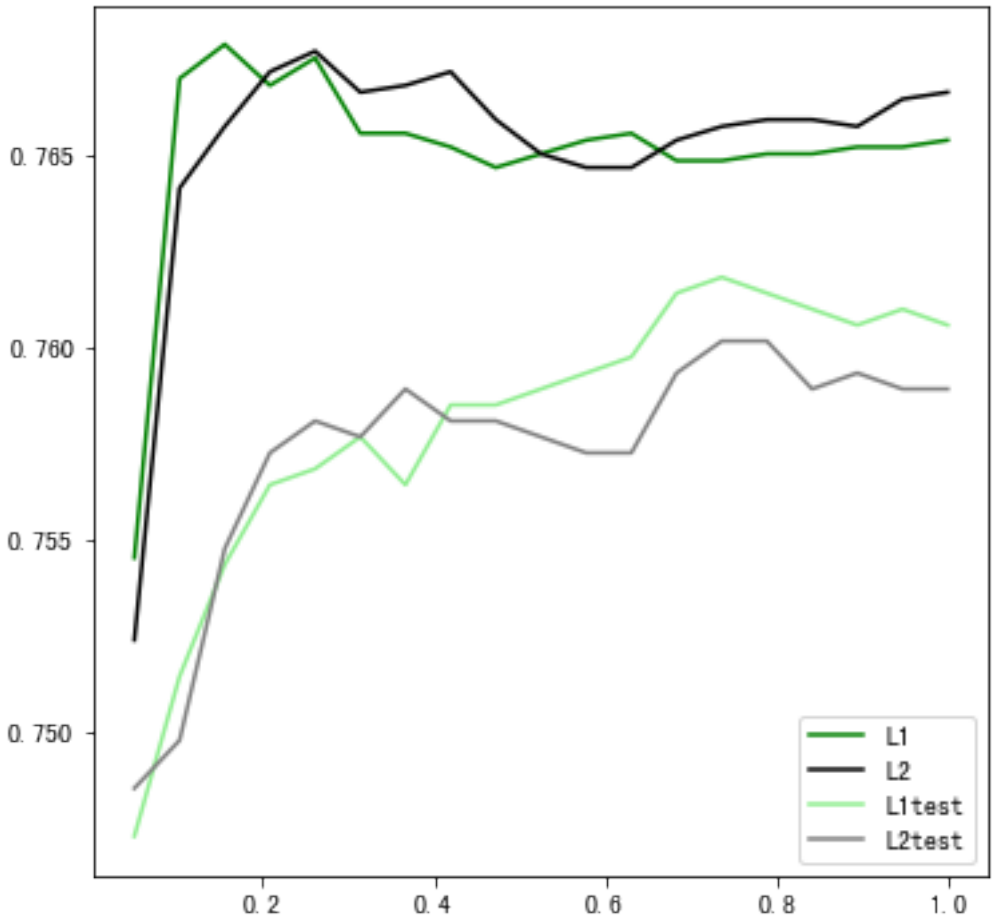

结果说明：选择 L1 正则化，正则化强度倒数 C 选择 0.7，这样的模型效果最好

[28]:
```
# L1 正则化训练模型
lrl1 = LR(penalty="l1",solver="liblinear",C=0.7,max_iter=1000)
lrl1 = lrl1.fit(x_total,y_total)
print('模型准确度：',accuracy_score(lrl1.predict(x_total),y_total))
print('模型系数：\n',lrl1.coef_)
print('模型参数有：',(lrl1.coef_ != 0).sum(axis=1),'个')

# 找出系数最大的参数（即为对结果影响最大的参数）
print('对结果影响最大的正参数为:',data.columns[lrl1.coef_.argmax()])
```

```
print('对结果影响最大的负参数为:',data.columns[lrl1.coef_.argmin()])
print('对结果影响最大的正参数的系数为:',lrl1.coef_.flatten()[lrl1.coef_.
 ↪argmax()])
print('对结果影响最大的负参数的系数为:',lrl1.coef_.flatten()[lrl1.coef_.
 ↪argmin()])
```

```
模型准确度:  0.7643177290836654
模型系数:
 [[-3.22652673 -2.29079155 -3.04630939 -1.69582002 -0.75087287 -0.42465768
  -1.3672136   1.92955429  2.89301685  2.3130234   2.17308606  2.08715427
   1.55954836  1.60328178  2.11837017  0.83620244  0.65439386  0.22819326
   0.58999877  0.29839887  0.71820502  0.55149647 -0.43718547  0.75992479
   0.50427094  0.35039226]]
模型参数有:  [26] 个
对结果影响最大的正参数为: cardnum
对结果影响最大的负参数为: creded
对结果影响最大的正参数的系数为: 2.8930168487834664
对结果影响最大的负参数的系数为: -3.2265267349983078
```

[29]:
```
print('模型所有参数: ')
[*zip(data.columns[:-1],lrl1.coef_.flatten().tolist())]
```

```
模型所有参数:
```

[29]:
```
[('creded', -3.2265267349983078),
 ('debitF', -2.2907915531106036),
 ('meanpay', -3.0463093918487223),
 ('billnum', -1.6958200242031487),
 ('debitM', -0.7508728683434108),
 ('zhongxingM', -0.42465767592533515),
 ('sidaM', -1.3672136000742854),
 ('xindaiR', 1.9295542870595672),
 ('cardnum', 2.8930168487834664),
 ('xindaiF', 2.313023404765529),
 ('maxpay', 2.173086055614373),
 ('zhuanzhangF', 2.087154269760282),
 ('gongjiaoF', 1.5595483643010029),
```

```
('zhuanzhangR', 1.603281783178127),
('age', 2.118370166274002),
('gongjiaoR', 0.8362024352194206),
('sidaF', 0.6543938611480398),
('sidaR', 0.2281932564066994),
('zhongxingF', 0.5899987732884395),
('zhongxingR', 0.29839886513660197),
('xiaofeiF', 0.7182050157657706),
('jinkaF', 0.5514964737456358),
('zhuanzhangM', -0.43718546633767774),
('gongjiaoM', 0.7599247947894275),
('youxiM', 0.504270942558938),
('xindaiS', 0.35039225633795096)]
```

1. 其中有 8 个特征的参数为负数，即“借贷比率、借记类 F、所有行为均值、交易笔数、借记类 M、中型银行 M、四大行 M、转账类 M”，意味着这些特征越大，预测结果越接近 0 类别（即未违约），其中“借贷比率”的系数绝对值最大，即借贷比率在对预测是否违约的结果中影响因素最大。
2. 剩余 18 个特征的参数均为正数，意味着这些特征越大，预测结果越接近 1 类别（即违约），其中“银行卡数”的系数最大，即银行卡数在对预测是否违约的结果中影响因素最大。

0.1.6 问题 4. 使用任务 3 的模型，对全部样本进行预测，计算 AUC 值，并绘制 ROC 曲线，对模型的效果进行评估

[62]:
```
# 通过 decision_function() 计算得到的 y_score 的值，用在 roc_curve() 函数中
y_score = lrl1.decision_function(x_total)

# 计算真正率和假正率
fpr,tpr,threshold = roc_curve(y_total, y_score)

# 计算 AUC 的值
roc_auc = auc(fpr,tpr)
print('AUC:',roc_auc)

# 画出 ROC 曲线
lw = 2
plt.figure(figsize=(8,8))
```

```
plt.plot(fpr, tpr, color='darkorange',
         lw=lw, label='ROC curve (area = %0.2f)' % roc_auc)
plt.plot([0, 1], [0, 1], color='navy', lw=lw, linestyle='--')
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('FPR: 假正例率',fontsize='large')
plt.ylabel('TPR: 真正例率',fontsize='large')
plt.title('ROC 曲线',fontsize='large')
plt.legend(loc="best")
plt.show()
```

```
AUC: 0.8268438496976998
```

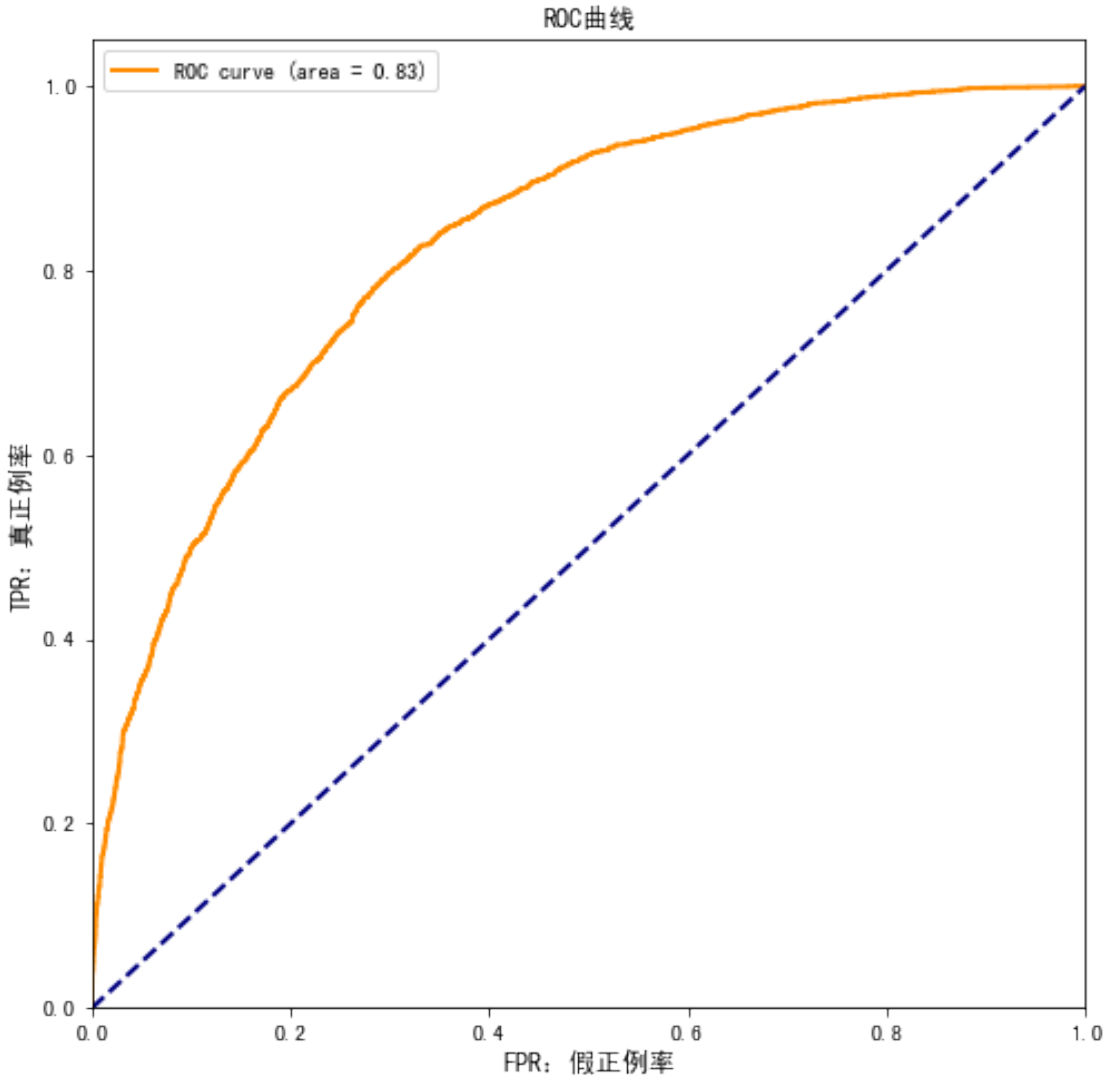

从 ROC 曲线中可以看出本模型预测效果较好，ROC 曲线凸性较大，其中 AUC 面积占到了 0.83

1. 其中有 8 个特征的参数为负数，即“借贷比率、借记类 F、所有行为均值、交易笔数、借记类 M、中型银行 M、四大行 M、转账类 M”，意味着这些特征越大，预测结果越接近 0 类别（即未违约），其中“借贷比率”的系数绝对值最大，即借贷比率在对预测是否违约的结果中影响因素最大。
2. 剩余 18 个特征的参数均为正数，意味着这些特征越大，预测结果越接近 1 累呗（即违约），其中“银行卡数”的系数最大，即银行卡数在对预测是否违约的结果中影响因素最大。

0.1.7 问题 5. 任务 4 中对每个训练样本预测出了非违约的概率，按照非违约率从高到低排序，将全部样本分为 5 组人群：非违约率最高的 20% 用户、...、非违约率最低的 20% 用户，计算五类人群的平均非违约概率，从高到低排序，绘制柱状图；对结果的商业应用进行解读。

[38]:
```
# 计算预测未违约、违约概率
y_pred_prob = lrl1.predict_proba(x_total)

# 将结果生成 DataFrame
data_prob = pd.DataFrame(y_pred_prob,columns=['未违约概率','违约概率'])

# 对未违约概率进行等频分箱，每个箱中样本数量相同
data_prob["未违约分箱"] = pd.qcut(data_prob["未违约概率"],5,labels=['未违约排名 5','未违约排名 4','未违约排名 3','未违约排名 2','未违约排名 1'])
```

[55]:
```
# 计算五类人群的平均非违约概率
prob_result = []
for i in range(1,6):
    a = np.array(data_prob["未违约概率"])[np.where(data_prob["未违约分箱"] == '未违约排名%d' % i)].mean()
    prob_result.append(a)
prob_result
```

[55]:
```
[0.9521260659450207,
 0.8566989001722156,
 0.7237079192346454,
 0.5406155105442119,
 0.2576677066956358]
```

[63]:
```
# 绘制柱状图
plt.figure(figsize=(13, 4))
plt.subplot(121)
x = ['未违约排名 5','未违约排名 4','未违约排名 3','未违约排名 2','未违约排名 1'][:
 ↪:-1]
y = prob_result
plt.bar(x,y,width=0.5, color=['b','r','g','y','c'])
plt.title("柱状图:五类人群的平均非违约概率",fontsize='large')
plt.xlabel('图 5 五类人群的平均非违约概率',fontsize='medium')
plt.ylabel('非违约概率',fontsize='medium')
plt.show()
```

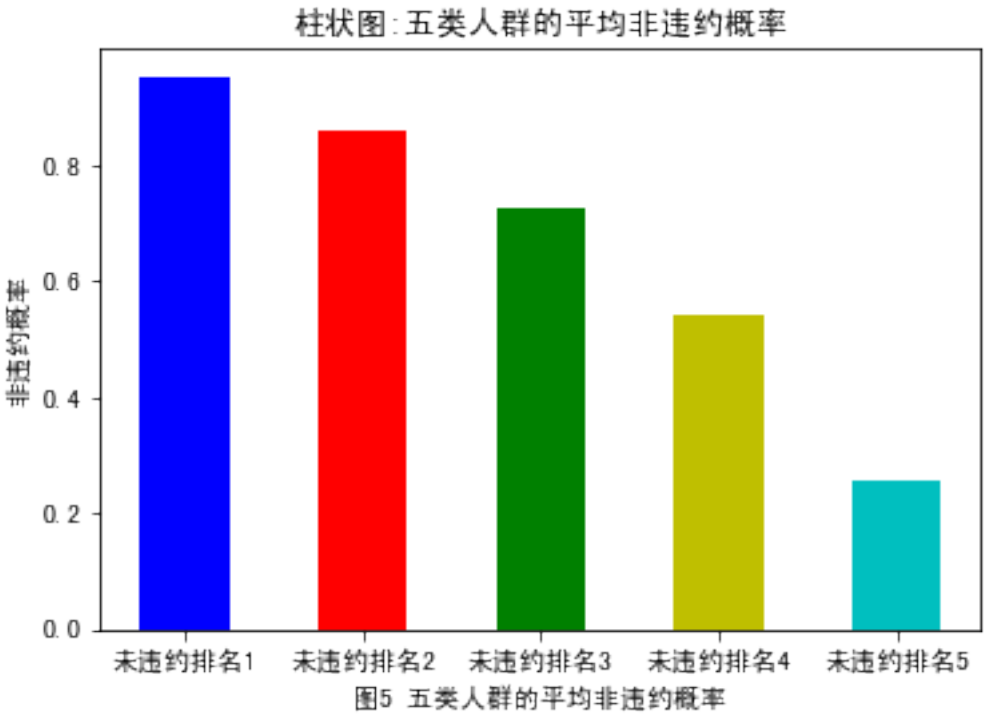

从预测概率的结果可以得出，5 类人群平均非违约概率分别为：95.21%、85.67%、72.37%、54.06%、25.77%，从概率上看，前四类人群的非违约概率均大于 50%，若按逻辑回归模型会将结果归为“未违约”类别，可以针对前四类用户的特征进行进一步的探索，而最后一类人群的未违约概率较小，模型会将其分类为“违约”类别。